

BLOC 3 - PIPELINES DE DONNÉES

Détection de fraude bancaire en temps réel

Un pipeline ETL automatisé avec Airflow, MLflow et PostgreSQL

Aïcha FATHELLAH

Projet Automatic Fraud Detection

Le problème et le besoin métier

Le problème

La fraude à la carte bancaire coûte plus d'**un milliard d'euros par an** en Europe.

Détecter une fraude est aujourd'hui faisable ; la traiter en continu, automatiquement, est le vrai défi.

Deux besoins exprimés

1

Être alerté d'une fraude


Une notification, dès qu'elle est détectée

2

Recevoir le bilan du matin

Les paiements et fraudes de la veille

Vue d'ensemble de l'infrastructure




Le flux ETL, chaque minute

Le processus ETL



Deux garde-fous : le contrôle qualité (quarantaine) et l'alerte en cas de fraude.

DAG ingestion_paiements — déclenché chaque minute



Choix techniques et sécurité



Tout en local, Docker

Reproductible et gratuit. Le cloud reste une évolution possible.



Bases isolées

Un compte par base, moindre privilège. Chaque service ne voit que ses données.



Données personnelles écartées

Nom, adresse, carte retirés. Carte anonymisée. Conformité RGPD.



Contrôle qualité

Les paiements douteux sont mis en quarantaine, jamais perdus.



Surveillance

Chaque passage est tracé : volume, rejets, durée de traitement.



Modèle versionné

Rangé dans MLflow, rechargé à la demande, réentraînable.

Résultats et pistes d'amélioration

96 %

Précision du modèle

70 %

Fraudes détectées (rappel)

1/min

Paielements traités, en continu

Pistes d'amélioration

- Mettre le modèle en cache pour accélérer le traitement
- Ajuster le seuil de décision pour attraper plus de fraudes
- Passer au cloud et au mode distribué si le volume augmente