



PROJET STRIPE

Architecture de données intégrée OLTP, OLAP et NoSQL

Plateforme de paiement : transactions, analyse, temps réel, détection de fraude et personnalisation

Aïcha Fathellah | Octobre 2026



Le besoin : une architecture unifiée pour une croissance mondiale



Transactions

Paielements,
remboursements,
litiges, abonnements :
disponibles et
cohérents



Analyses

Chiffre d'affaires,
segmentation,
conformité en temps
quasi réel



Données variées

Journaux, avis,
navigation : JSON, XML
et fichiers binaires



Intégration

Flux continu et
cohérent entre les trois
bases




Conformité

RGPD, PCI-DSS, CCPA :
chiffrement, accès,
audit

Objectif : chaque donnée naît une seule fois, dans la base transactionnelle, puis alimente en temps réel l'analyse, l'intelligence artificielle et la conformité.


Architecture globale : une source de vérité, trois usages



Trois modèles de données : à chaque base son usage

Base transactionnelle


PostgreSQL 17



- 12 tables en troisième forme normale
- ACID : contraintes et déclencheurs dans la même transaction
- Réplica en continu, bascule par promotion

Entrepôt analytique

Schéma en étoile



- 7 dimensions, faits partitionnés par mois
- Agrégats quotidiens et 3 vues matérialisées
- Chargement incrémental toutes les 15 minutes

Base NoSQL


MongoDB 8.0



- 7 collections validées et GridFS : JSON, XML, binaire
- Imbriquer ce qui est lu ensemble, référencer le reste
- Profils et registre des modèles pour l'IA

Intégration : les trois bases partagent les mêmes identifiants ; un paiement se suit de l'une à l'autre.

Pipeline : chaque paiement noté en temps réel, sans perte



540 ms

latence médiane, de
l'enregistrement à la décision



0 perte

journal conservé jusqu'à lecture
; position validée après
traitement



Ordre

paiements d'un même client
traités dans l'ordre (clé Kafka)

Traitements par lots orchestrés par Airflow

Toutes les 15 minutes

Alimentation incrémentale de l'entrepôt,
contrôles de qualité

Chaque jour

13 contrôles de conformité, rapport daté

Chaque lundi

Réentraînement des modèles, règle champion
/ challenger

Sécurité, conformité et supervision : prouvées par des tests



TLS 1.3

échanges chiffrés avec la base transactionnelle, serveur vérifié



11

rôles : un compte par programme ou par usage, droits jusqu'à la colonne



45

tests automatisés des droits et du chiffrement, tous conformes



13

contrôles RGPD, PCI-DSS et disponibilité chaque jour, rapport daté


Identifier, optimiser : la supervision a détecté un cache à 85,7 % ; la mémoire de PostgreSQL a été portée de 128 à 512 Mo.



Grafana : 15 indicateurs en continu et 5 règles d'alerte (capture interrompue, entrepôt non alimenté, dérive...)

Résultats : la fraude repérée, le métier éclairé

Part de litiges pour fraude selon la décision du modèle (%)



Lecture indicative : l'historique a été noté par un modèle entraîné sur ces mêmes données. Mesure rigoureuse : AUC de 0,99 sur les 20 % de paiements les plus récents, jamais vus.

55,5 %

du chiffre d'affaires réalisé par les Champions, un quart des clients

17 requêtes

SQL et NoSQL : chiffre d'affaires, fraude, segmentation

1 paiement, 3 bases

suivi par son identifiant commun : caisse, NoSQL, entrepôt

Limites assumées, architecture prête pour le cloud



Démonstration

- Poste unique, sans redondance
- Rythme accéléré du générateur
- Bascule manuelle vers le réplica
- TLS limité à la base transactionnelle



Architecture cible

- Services gérés sur trois zones
- Kafka à trois courtiers, MongoDB réparti
- Kubernetes et Terraform
- Chiffrement généralisé, alertes notifiées

Une architecture complète, testée et reproductible : 16 services, 7 diagrammes, 17 requêtes métier.




Annexes

Diagrammes détaillés et compléments pour les questions




Annexe 1 - Architecture globale




Rangée du haut : flux temps réel ; milieu : réplia et entraînement ; en dessous : traitements par lots Airflow ; en bas : supervision. Flèches pleines : données ; tirets : pilotage ; pointillés : lecture seule.

Annexe 2 - Modèle entité-relation de la base transactionnelle



PK : clé primaire ; FK : clé étrangère ; UQ : valeur unique. Patte de corbeau : plusieurs ; trait : un ; cercle : facultatif. En orange : colonnes sensibles.

Annexe 3 - Schéma en étoile de l'entrepôt



Au centre, les faits (un paiement par ligne, mesures repérées par M) ; autour, sept dimensions d'analyse ; à droite, audit, agrégats, vues matérialisées et optimisations.

Annexe 4 - Modèle de données NoSQL

PAIEMENT NOTÉ EN TEMPS RÉEL transactions_enrichies		
_id	_id	id du paiement (caisse)
REF	client_id	vers profils_clients
REF	marchand_id	vers caisse : marchands
	montant	décimal (Decimal128)
	devise, statut	chaîne, énumération
	date_heure	date
{ }	contexte	objet
	montant_eur, pays_ip, type_appareil	
{ }	indicateurs	objet : 10 indices
{ }	score	objet
	valeur, modele, version	
	decision	accepter, verifier, bloquer
{ }	historique_statuts	liste (20 au plus)
	statut, date	
	latence_ms	entier
	date_traitement	date

HABITUDES ET PERSONNALISATION profils_clients		
_id	_id	id du client (caisse)
	code_pays, date_inscription	chaîne, date
	nb_paiements	entier
	montant_total_eur, montant_moyen_eur	décimal
{ }	pays_connus	codes pays
{ }	appareils_connus	types d'appareils
{ }	marchands_connus	identifiants
{ }	horodatages_recents	dates (24 heures)
{ }	produits_achetes	identifiants
{ }	categories_preferrees	catégorie : nombre
{ }	recommandations	liste (5 produits)
	produit_id, score, origine	
{ }	recommandations_modele	nom, version
	date_maj	date

REGISTRE DES MODÈLES modeles_ml		
_id	_id	Objectid
	nom, version	unique (index)
	statut	candidat, actif, archive
	date_entrainement	date
	seuil_verification, seuil_decision	0,5 et 0,8
{ }	periode	début, fin des données
{ }	metriques	objet
	entrainement, production, suivi	AUC, latence, dérive
REF	fichier_gridfs_id	vers GridFS « modeles »

JOURNAUX TECHNIQUES journaux_applicatifs		
_id	_id	Objectid
	horodatage	date (expiration 90 j)
	niveau	DEBUG à CRITIQUE
{ }	source	objet
	service, hôte	chaîne
	message	chaîne
	code_http, duree_ms	nombres facultatifs

Imbriquer ou référencer

Imbriqué : ce qui est lu ensemble, en une seule lecture (score, indices, événements d'une visite, historique)
Listes bornées (20, 500) : un document ne grossit pas sans limite
Référéncé : ce qui vit ailleurs ou grossit (client, marchand, fichiers binaires)
Identifiants communs avec la caisse : écritures idempotentes, liens entre bases

Validation et index

7 collections avec règles \$jsonSchema :
champs obligatoires, types, valeurs admises ; champs supplémentaires admis
Structures variables : avis ou enquête, message texte ou fichier (anyOf)
Index composés client et date, unicité nom et version des modèles, recherche plein texte en français, expiration à 90 j

VISITES SUR LES SITES MARCHANDS sessions_navigation		
_id	_id	id de session
REF	client_id	facultatif : visiteur anonyme
REF	marchand_id	vers caisse : marchands
	debut, fin	date
{ }	appareil	objet : type
{ }	evenements	liste (500 au plus)
	type, horodatage, page	page vue, panier, paiement...
REF	transaction_id	si la visite aboutit

AVIS ET ENQUÊTES (STRUCTURES VARIABLES) avis_clients		
_id	_id	Objectid
	type	avis ou enquête
REF	client_id, marchand_id	vers caisse
	date	date
	note	1 à 5 (si avis)
	commentaire	recherche plein texte
{ }	reponses	si enquête
	question, reponse	

MESSAGES BANCAIRES ET JUSTIFICATIFS documents_externes		
_id	_id	Objectid
	type	message ou pièce
	format	xml, json, pdf, image
	date_reception	date
{ }	references	objet
REF	transaction_id, litige_id	vers caisse
	contenu_brut	si XML ou JSON
{ }	champs_extraits	motif, montant...
REF	fichier_gridfs_id	si PDF ou image


STOCKAGE DE FICHIERS BINAIRES GridFS « fichiers » et « modeles »		
fichiers.files, fichiers.chunks	justificatifs PDF, images	
modeles.files, modeles.chunks	modèles entraînés	
découpage en blocs de 255 Ko	sans limite de 16 Mo	

Sécurité

Un compte par programme, droits définis collection par collection
Aucun droit de suppression accordé
Aucune donnée de carte ni adresse IP
Journaux supprimés après 90 jours (RGPD)


Champs décalés : imbriqués dans le précédent. _id : identifiant ; REF : référence ; { } : objet ; [] : liste. Pas de traits : MongoDB ne vérifie pas les références.

Annexe 5 - Architecture du pipeline



En haut, les huit étapes d'un paiement en temps réel et leurs garanties ; en bas, les trois chaînes Airflow avec le nom exact de chaque tâche et leur enchaînement.

Annexe 6 - Cycle de vie des modèles



Lecture dans le sens des aiguilles d'une montre : collecte, indices, entraînement, registre, déploiement, suivi, réentraînement. Au centre, les résultats des deux modèles.

Annexe 7 - Sécurité et conformité

Qui accède à quoi : un compte par programme, un rôle par usage

Compte (programme ou personne)	Base transactionnelle (OLTP)	Entrepôt analytique (OLAP)	Base NoSQL (MongoDB)
svc_generateur <i>application de paiement</i>	role_application_paiements crée paiements, clients, remboursements et litiges ; ni modification ni suppression	aucun accès	role_generateur_nosql insère navigation, avis, journaux, documents ; aucun accès aux paiements ni aux profils
svc_flux <i>consommateur, entraînement</i>	role_flux_temps_reel lit les paiements (sans adresse IP) et le pays des clients, jamais l'e-mail ; écrit le seul score	aucun accès	role_flux_nosql lit et écrit fiches, profils et modèles ; aucune suppression
svc_airflow, svc_airflow_dwh <i>orchestrateur</i>	role_orchestrateur lecture seule (e-mail chiffré, sans la clé) et statistiques de réplication	role_chargement écrit faits, dimensions et agrégats ; vues rafraîchies par fonction dédiée	role_orchestrateur_nosql lit journaux et index pour les contrôles ; consigne leur résultat
cdc_debezium <i>capture des changements</i>	réplication et lecture de la seule table des paiements ; adresse IP exclue du flux	aucun accès	aucun accès
replicator <i>réplica</i>	réplication physique uniquement, connexion chiffrée	aucun accès	aucun accès
svc_grafana, svc_grafana_dwh <i>supervision</i>	role_supervision statistiques internes ; date, statut et score des paiements seulement	role_supervision suivi des chargements et dates de chargement seulement	aucun accès
analyste_demo <i>analyste</i>	aucun accès	role_analyste faits, dimensions, agrégats et vues ; pas de journal d'audit	aucun accès
auditeur_demo <i>auditeur</i>	aucun accès	role_auditeur journal d'audit et suivi des chargements ; pas de paiements ni de clients	aucun accès

Comptes administrateurs réservés à la création des bases et des rôles, jamais utilisés par les programmes. Comptes svc_ et de supervision : mots de passe aléatoires de 48 caractères.

Références réglementaires couvertes

RGPD : article 5 (minimisation, limitation de la conservation des journaux à 90 jours), article 25 (protection dès la conception : adresse IP exclue du flux), article 32 (sécurité du traitement : chiffrement, contrôle d'accès, traçabilité)

PCI-DSS : exigence 3 (aucun numéro de carte stocké), exigence 4 (chiffrement des transmissions), exigence 7 (restriction des accès), exigence 8 (identifiants protégés), exigence 10 (journalisation et surveillance)

Comment les données sont protégées

1. Réseau et transport

Chiffrement TLS 1.3 obligatoire vers la base transactionnelle, serveur vérifié (verify-full) ; connexions en clair refusées

2. Authentification

Comptes dédiés, mots de passe vérifiés par SCRAM-SHA-256 ; secrets hors du code et du dépôt (fichier .env exclu de Git)

3. Autorisation

Contrôle d'accès par rôles : droits par table, par colonne et par collection ; aucun compte de service ne peut supprimer dans la caisse ni MongoDB

4. Données

E-mails chiffrés (pgcrypto), cartes remplacées par un jeton, minimisation dans l'entrepôt, adresse IP hors du flux

5. Traçabilité

Journal d'audit non modifiable (déclencheurs), copié dans l'entrepôt, lisible par le seul auditeur

6. Contrôle continu

13 contrôles quotidiens (rapport daté), 5 règles d'alerte, 45 tests automatisés des droits et du chiffrement

de la couche la plus extérieure (le réseau) à la plus intérieure (le contrôle continu)

Matrice : rôle et droits de chaque compte sur chaque base (case blanche : aucun accès). À droite : six couches de protection, de la plus extérieure à la plus intérieure.

Annexe 8 - Choix technologiques et alternatives écartées

Besoin	Choix	Alternative écartée et raison
Base transactionnelle	PostgreSQL 17	MySQL : décodage logique et partitionnement moins complets ; SQL distribué réservé à la cible
Entrepôt	PostgreSQL en étoile	Entrepôts en colonnes (Snowflake, BigQuery) : retenus pour la cible, même modèle en étoile
Base NoSQL	MongoDB 8.0	Cassandra : requêtes moins souples sur les documents imbriqués
Capture des changements	Debezium	Interrogation périodique : charge, latence, suppressions manquées
Diffusion	Kafka	RabbitMQ : pas de relecture d'historique ni d'ordre par clé à grande échelle
Orchestration	Airflow	Cron : ni dépendances, ni nouvelles tentatives, ni historique
Supervision	Grafana	Interfaces propres à chaque outil : pas de vue unifiée ni d'alerte transversale

Annexe 9 - Cohérence entre les bases et résolution des conflits

Base ou règle	Délai ou principe	Mécanisme
Base transactionnelle	Immédiat : source de vérité	Transactions ACID
Réplica	Quelques millisecondes	Réplication physique en flux
Base NoSQL	Environ 0,5 seconde	Capture des changements, Kafka, consommateur
Entrepôt	15 minutes au plus	Chargement incrémental par filigrane
Un seul écrivain par donnée	Aucune écriture concurrente	Application, consommateur (score) et Airflow (entrepôt) séparés
La source fait foi	Réécriture à partir de la caisse	Écritures idempotentes, relecture des événements Kafka
Réconciliation	Contrôle après chaque chargement	Comptages comparés source et entrepôt, agrégats et faits

Annexe 10 - Les dix-sept requêtes métier

N°	Question	Base	N°	Question	Base
1	Chiffre d'affaires par mois et région	Entrepôt	10	Historique d'audit d'un paiement	Transactionnelle
2	Évolution hebdomadaire (fenêtres)	Entrepôt	11	Paievements bloqués et indices	NoSQL
3	Dix marchands les plus rentables	Entrepôt	12	Décisions et latence sur 24 heures	NoSQL
4	Pays les plus exposés à la fraude	Entrepôt	13	Recommandations d'un client	NoSQL
5	Performance des produits	Entrepôt	14	Entonnoir de conversion	NoSQL
6	Segmentation RFM	Entrepôt	15	Notes et recherche plein texte	NoSQL
7	Efficacité du modèle de fraude	Entrepôt	16	Dossiers de litige (XML, PDF)	NoSQL
8	Derniers paiements d'un client	Transactionnelle	17	Un paiement dans les trois bases	Les trois
9	Taux de litige par marchand	Transactionnelle			

Annexe 11 - Architecture cible dans le cloud

Composant	Démonstration	Cible (AWS)	Cible (Azure)
Base transactionnelle	PostgreSQL et un réplica	Aurora PostgreSQL multi-zones	Azure Database for PostgreSQL
Diffusion	Kafka, un nœud	Amazon MSK, trois courtiers	Event Hubs (protocole Kafka)
Base NoSQL	MongoDB, un nœud	MongoDB Atlas, grappe répartie	MongoDB Atlas ou Cosmos DB
Entrepôt	PostgreSQL en étoile	Amazon Redshift	Azure Synapse Analytics
Orchestration	Airflow	Amazon MWAA	Airflow sur Kubernetes (AKS)
Modèles	FastAPI et registre MongoDB	SageMaker	Azure Machine Learning
Supervision	Grafana	Managed Grafana et CloudWatch	Managed Grafana et Azure Monitor
Calcul	Docker Compose	EKS et Terraform	AKS et Terraform